投手智囊 · 数据采集与分工（队员版，可转发）

> 2026-09-07 定稿。读完就知道**自己干什么、交什么、什么时候交**。 想看产品全貌读《01-产品文档-v1.0》，想看复赛方案读《02-复赛蓝图-v0》，本文只讲"活怎么干"。

0. 一页读懂

产品：面向中小企业的广告投放策略顾问——商家说"卖什么、预算多少、要什么结果"，助手输出"投给谁/出多少价/何时投/配什么素材"四件套 + 数值区间预估。 **复赛**：9/19 线上，90 分钟蓝鹰敏学平台操作。我们所有准备，最终汇入一个点：

```
【复赛平台配置】= 挂 3 个知识库 + 贴系统提示词 + 挂计算器
           ↑                    ↑                    ↑
   三条库线（W1/W2/W3）     提示词线（W4）        工具已实测可用
           └───────── 被测试线（W5）验证，迭代到 9/18 ─────────┘
```

1. W2 · 基准库流水线（徐毅）⭐ 关键路径

你的活一句话：把"原始 CSV"变成"助手能引用的基准表"。 所有脚本由 Claude 写好交你，你负责跑通、检查结果是否合理、按格式整理。

> 名词解释：基准表 = 按"合作方式×广告类型×素材类型"分组的 CTR/CVR/CPM 参考区间。助手回答"大概多少曝光、多少留资"全靠查这张表。

步	动作	产出	截止
1	注册百度账号，下载飞桨数据集：**aistudio.baidu.com/datasetdetail/55268**（ad_performance.csv，889行×13字段，免费）	原始 CSV	**9/9**
2	跑 `explore_data.py`（Claude 提供）：看字段分布/缺失值/分组数，写 1 页探查记录	探查报告	9/9
3	跑 `build_benchmark.py`：分组统计各组 CTR/CVR/CPM 的均值 + P25/P50/P75	基准区间表 CSV	9/10
4	（Claude 做）CSV 转 md 表 + 写口径说明	基准库文档 ×2	9/10
5	跑 `synthesize_curve.py`：生成出价梯度（1.0–3.0 倍）→ 拟合"出价-曝光-成本"曲线	曲线数据 +说明	9/10
6	跑 `verify_monotonic.py`：校验"出价升→曝光升"的单调性	校验报告	9/10
7	汇总 4 份 md = 基准库，交队长	基准库打包	9/10

兜底：第 1 步下载失败 → 立刻告诉队长，转全量合成数据（脚本支持，基准表照出），答辩口径同步调整。

2. W3 · QA 文档化库（陈钰涛）

为什么有这个库：平台实测，"QA 知识库"类型**挂不上助手**，只能挂文档库。所以问答对必须写成文档，让平台按文档检索。 **它在流程里的作用**：用户提问 → 平台自动拿问题和知识库所有片段做语义匹配 → 命中哪节就照哪节的答法回答。节标题里写**同义问法**就是为了提高命中率（用户说"拉新客要多少钱"也能命中"预算怎么定"那节）。所以它管两件事：口语归一化 + 关键问题答法一致。

形态示例（每问一节，标题带同义问法，正文是答法要点）：

```
## 日预算 500 够不够投？（预算多少合适 / 一天投多少钱 / 预算怎么定）
- 先确认目标类型（曝光/点击/留资/下单），不同目标口径不同
- 对照基准表给出曝光-转化区间，判断 500 元能否达到目标
- 达不到时给两个方案：提预算 或 降目标，并说明理由
```

你的步骤：①采样 50–80 条**真实问法**（知乎搜"中小企业 广告投放""信息流投放 怎么投"；巨量学堂 FAQ；腾讯广告帮助中心——每条记下来源链接）→ ②筛 30–50 条 → ③每条写 QA 节（同义问法 3–5 个）→ ④按模板合并成 md 交队长入库。**截止 9/12**。 **与测试集的关系**：同源分流——一部分写成 QA **教**助手，另一部分留作测试集**考**助手，不要完全重合。

3. W1 · 规则方法论库 = 7 份 SOP（Claude 起草 → 队长审）

SOP = 写给助手看的"作业规则文档"，助手回答某类问题时照着规则说，不自由发挥。

#	文档	给哪个节点	内容来源
1	需求解析规则（三要素/追问/默认值/口语→术语）	节点1	自编
2	竞价方式判定规则（CPC/oCPM/CPA）	节点2	自编（参考腾讯广告大赛思想）
3	渠道适配规则（行业×人群×预算→渠道类型+冷启动门槛）	节点2	自编（参考巨量学堂公开方法论）
4	人群定向建议规则	节点3	自编
5	出价单调性规则	节点5	**AuctionNet（阿里妈妈）逻辑骨架**：Claude 拉 GitHub README+论文摘要提炼，不下载 80GB
6	预算分配规则（比例/爬坡/客单价分级）	节点6	自编（参考提炼笔记的公式与结构）
7	投放方法论总纲 + 合规禁词表	节点4/横切	**腾讯 TAAC2026 数据卡**提炼思想 + 广告法禁词（flk.npc.gov.cn 查原文，只提炼清单）

节奏：写作规范模板 9/8（Claude）→ 初稿 9/10 → 队长审定稿 9/11。

4. W4 提示词线 / W5 试搭测试线

- **W4**：Claude 起草系统提示词（六节点流程约束 + 四段式输出 + 兜底 + 禁词）9/10 → **陈钰涛红队**（只攻击不代笔：找漏洞、出意见清单）9/11 → 队长试搭实测升版 9/12。
- **W5**：队长平台试搭 9/12（挂 3 库、检查切片质量、扩写画像效果、计算器口径验证）；陈钰涛测试集 30–50 条 9/14（覆盖投前/单调性/合规/投后兜底四类，每条标注期望行为）；全队计时演练 9/15–9/18。

5. 每人任务卡

人	一句话职责	交付物	截止
徐毅	数据流水线：原始 CSV → 基准表	基准库 4 份 md + 探查报告	**9/10（关键路径）**
陈钰涛	真实问法采样 → QA 库 + 测试集；提示词红队	QA 库 md、测试集、红队意见清单	9/12 / 9/14 / 9/11
倪天夏	SOP 审定、平台试搭、提示词 owner、全局统筹	审校意见、试搭结论、提示词定稿	9/11 / 9/12
Claude	起草全部文档与脚本、AuctionNet/TAAC 提炼、提示词初稿	写作模板、SOP×7、脚本×4、提炼笔记、提示词稿	9/8–9/10

6. 红线与约定（全员）

1. **原创**：一切入库文档自编。外部资料（含参考项目 cross-border-ai，提炼笔记在队内共享）**只读不搬**——比赛规则"内容原创、禁止抄袭"。
2. **术语**：用国内口径（ROI/CPA/冷启动/人群包），不用亚马逊黑话（ACOS/Listing/学习期）——映射表见提炼笔记。
3. **数值**：对用户一律"基于行业基准的建议区间，非精确预测"；计算器的口径必须出自基准库。
4. **交件格式**：全部 md，按《主题文件写作规范》（Claude 9/8 交）：标题带同义问法、每节自包含、层级≤三级。

7. 时间线总览

9/8 写作模板 ｜ **9/9** CSV 下载+探查（徐毅） ｜ **9/10** 基准库打包 + SOP 初稿 + 提示词初稿 ｜ **9/11** SOP 定稿 + 红队 ｜ **9/12** 试搭 + QA 库 + 提示词升版 ｜ **9/14** 测试集 ｜ **9/15–9/18** 计时演练 ｜ **9/19 复赛（线上）**